

PROJET NATACHA

Cluster d'IA Distribué & Autonome

Auteur : Thierry VIEIL | v33.12 | Mai 2026

Ce document récapitule l'architecture technique et logicielle du cluster **Natacha**, une intelligence artificielle distribuée sur trois nœuds matériels spécialisés communiquant via le protocole MQTT et des flux audio UDP.

1. Architecture du Cluster

Organe	Matériel	Rôle Principal
 L'Oreille	Ryzen 5 5500U	Transcription (STT) via Whisper
 Le Cerveau	Core i5 14ème Gen	Inférence (LLM) & Mémoire (RAG)
 La Bouche	Orange Pi 6 Plus	Synthèse Vocale (TTS) via Piper

2. Le Cerveau (Nœud Central)

Matériel : Intel Core i5-14500 (14ème Génération) - 12 Threads.

Logiciels : llama.cpp (Serveur), ChromaDB (Mémoire), Kiwix (Savoir local).

Installation de llama.cpp

```
git clone https://github.com/ggerganov/llama.cpp
cd llama.cpp && mkdir build && cd build
cmake .. && cmake --build . --config Release
```

Configuration du Modèle (OpenHermes 2.5)

Le modèle est stocké dans `/home/vieil/modeles_natacha/`. Nous utilisons la version Q4_K_M pour un équilibre optimal performance/mémoire.

```
wget https://huggingface.co/TheBloke/OpenHermes-2.5-Mistral-7B-GGUF/resolve/main/openhermes-2.5-mistral-7b.Q4_K_M.gguf
```

3. La Bouche (Synthèse Vocale)

Matériel : Orange Pi 6 Plus (ARM64).

Moteur : Piper TTS (Modèle Siwis Medium).

Installation de Piper

```
mkdir -p ~/piper_bin && cd ~/piper_bin  
wget https://github.com/rhasspy/piper/releases/download/v1.2.0/piper_arm64.tar.gz  
tar -xf piper_arm64.tar.gz
```

Environnement Python (tts_env)

```
conda create -n tts_env python=3.10 -y  
conda activate tts_env  
pip install -r ~/Natacha-Project/modules/mouth/requirements.txt
```

4. Services Système (Systemd)

Chaque module est automatisé via un service Linux pour garantir un redémarrage après coupure.

Cerveau (Cerveau_natacha.service)

```
[Unit]
Description=Cerveau de Natacha - Pont Intelligence
After=network-online.target mosquitto.service llama-brain.service

[Service]
Type=simple
User=vieil
WorkingDirectory=/home/vieil/Natacha-Project/modules/brain
ExecStart=/home/vieil/miniconda3/envs/cerveau_natacha/bin/python3 brain_v33_12.py
Restart=always
```

Note sur la maintenance : Toujours utiliser `journalctl -u [nom_du_service] -f` pour visualiser les logs en temps réel.

Projet Documenté via l'Assistant IA pour le dépôt GitHub de Thierry Vieil.

"Natacha : La résilience par la distribution."